

MC886 - Aprendizado de Máquina

Exercícios

Docente: Marcelo da Silva Reis

Monitores: Daniel Gratti (PED) e Guilherme Ito (PAD)

Campinas, 27 de abril de 2026

Vários exercícios foram retirados do ISLP [1] e/ou adaptados de Géron [2].

1 Redes neurais “fully connected” ou “feedforward” (MLPs)

- 1.1. [Géron 10.1] Desenhe uma rede neural utilizando perceptrons como neurônios para calcular a operação de ou exclusivo (XOR) $A \oplus B$. Utilize a função degrau de Heaviside ao invés da função sinal.
- 1.2. [Géron 10.2], adaptado Por que geralmente é preferível utilizar um classificador de regressão logística ao invés de um perceptron clássico? Como você pode ajustar um perceptron para torná-lo equivalente a um classificador de regressão logística? (*Obs: um perceptron é um modelo linear similar à regressão logística, porém com uma função Heaviside no lugar da função logística.*)
- 1.3. [Géron 10.3, adaptado] Por que a função de ativação logística foi um ingrediente chave na formação das primeiras feedforwards?
- 1.4. [Géron 10.4, adaptado] Nomeie três funções de ativação populares. Desenhe os seus respectivos gráficos de saída como função de valores de entrada.
- 1.5. [Géron 10.5, adaptado] Suponha que você tenha uma “feedforward” composta de uma camada de entrada com 10 neurônios, seguida de uma camada oculta com 50 neurônios e, finalmente, uma camada de saída com 3 neurônios. Todas as ativações utilizam ReLU.
 - Descreva a coleção θ que contém as matrizes de pesos $\mathbf{W}^{(\ell)}$ de todas as camadas da rede.
 - Escreva a equação que computa $f(X)$ em termos da coleção θ que você descreveu no item anterior.
- 1.6. [Géron 10.6, adaptado] De quantos neurônios você precisa na camada de saída se quiser classificar o e-mail como spam ou não spam? Que função de ativação você deve utilizar na camada de saída? Se, em vez disso, você quiser abordar o **MNIST**, de quantos neurônios você precisa utilizando qual função de ativação na camada de saída?

2 Redes neurais convolucionais (CNNs)

- 2.1. [Géron 13.1] Quais são as vantagens de uma CNN sobre uma “feedforward” totalmente conectada para classificação de imagens?
- 2.2. [Géron 13.4] Por que você adicionaria uma camada max pooling em vez de uma camada convolucional com o mesmo stride?
- 2.3. Qual é a finalidade de utilizar camadas convolucionais em redes neurais?
- 2.4. Como funciona a camada de pooling?
- 2.5. Cite e explique duas técnicas de regularização possíveis para redes convolucionais.
- 2.6. Indique maneiras para interpretar a saída das camadas convolucionais.
- 2.7. Considere uma camada convolucional com uma entrada de tamanho $109 \times 109 \times 3$, utilizando 64 filtros de tamanho $5 \times 5 \times 3$. Se o stride for igual a 1 e não houver padding, qual será o tamanho da saída? E com stride igual a 2 e 3?
- 2.8. O que é transfer learning e em quais situações é benéfico utilizar essa técnica?

3 Redes neurais recorrentes (RNNs)

- 3.1. Desenhe a arquitetura de uma rede neural recorrente com $p = 2$, $L = 5$ e $K = 3$. Indique nas arestas do seu diagrama os pesos da rede.
- 3.2. [Géron 14.1] Você pode pensar em algumas aplicações para uma RNN de sequência-a-sequência? Que tal uma RNN sequência-vetor? E uma RNN vetor-a-sequência?
- 3.3. [Géron 14.3] Como você poderia combinar uma CNN com uma RNN para classificar vídeos?
- 3.4. [Géron 14.5] Como você pode lidar com sequências de entrada de comprimento variável? E quanto às sequências de saída de tamanho variável?
- 3.5. Que problemas podem aparecer no teste em uma RNN treinada utilizando uma única série temporal (autorregressão)? O que pode ser feito para mitigar esse problema?

4 Retropropagação e outros tópicos avançados (que exigem a leitura de material além do ISLP)

- 4.1. Descreva, com o auxílio de um diagrama, a retropropagação passando entre duas camadas ocultas de uma MLP.
- 4.2. Descreva, com o auxílio de um diagrama, a retropropagação passando entre duas camadas convolucionais de uma CNN.

- 4.3. [Géron 13.2, adaptado] Considere uma CNN composta por três camadas convolucionais, cada uma com um kernel 3×3 um stride 2 e padding SAME (i.e., padding que garante que a saída terá o mesmo tamanho da entrada). A camada inferior gera 100 mapas, a do meio gera 200 e a de cima 400. As imagens de entrada são RGB de 200×300 pixels.
- a) Qual é o número total de parâmetros nessa CNN?
 - b) Se estimermos utilizando floats de 32 bits, quanto de memória RAM essa rede exigirá ao fazer uma previsão para uma única instância?
 - c) Sobre o item (b), e quando treinamos em um minilote de 50 imagens?
- 4.4. [Géron 13.3] Se a sua GPU fica sem memória durante o treinamento de uma CNN, quais são cinco coisas que você poderia tentar para resolver o problema?
- 4.5. [Géron 13.5] Quando você adicionaria uma camada de normalização de resposta local?
- 4.6. [Géron 13.6] Você pode citar as principais inovações da AlexNet ¹ em comparação com a LeNet ²? E as principais da GoogleNet (Inception) ³ e da ResNet ⁴?
- 4.7. Descreva num diagrama, indicando os pesos as arestas, o mecanismo de resíduo proposto na ResNet. Qual é a função desse mecanismo?
- 4.8. O que é o problema do gradiente desvanecente (“vanishing gradient”)? E o problema do gradiente explosivo (“exploding gradient”)? Quando esses problemas ocorrem? Quais técnicas podem ser utilizadas para evitá-los em modelos convolucionais?
- 4.9. Descreva, com o auxílio de um diagrama, a retropropagação operando entre duas camadas recorrentes de uma RNN.
- 4.10. O que é a área de eXplainable AI (XAI) e por que é fundamental? Quais técnicas podemos utilizar para interpretar nossos modelos convolucionais de forma compreensível e transparente?

Referências

- [1] Gareth James, Daniela Witten, Trevor Hastie, Robert Tibshirani, and Jonathan Taylor. *An Introduction to Statistical Learning with Applications in Python*. Springer, 2023.
- [2] Aurélien Géron. *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems*. ”O’Reilly Media, Inc.”, 2019.

¹en.wikipedia.org/wiki/AlexNet.

²en.wikipedia.org/wiki/LeNet.

³[en.wikipedia.org/wiki/Inception_\(deep_learning_architecture\)](https://en.wikipedia.org/wiki/Inception_(deep_learning_architecture)).

⁴en.wikipedia.org/wiki/Residual_neural_network.