

MC886 - Aprendizado de Máquina

Exercícios

Docente: Marcelo da Silva Reis

Monitores: Daniel Gratti (PED) e Guilherme Ito (PAD)

Campinas, 18 de maio de 2026

Vários exercícios foram retirados e/ou adaptados de Géron [1], assim como de “Introduction to Data Mining” (IDM) [2].

1 Redução de dimensionalidade


- 1.1. [Géron 8.1] Quais são as principais motivações para reduzir a dimensionalidade de um conjunto de dados? Quais são as principais desvantagens?
- 1.2. [Géron 8.2, adaptado] O que é a “maldição da dimensionalidade”? (Dica: está relacionada ao impacto de se aumentar o número de características de entrada do modelo sem aumentar também o n , número de pontos do dataset.)
- 1.3. [Géron 8.3] Uma vez reduzida a dimensionalidade de um conjunto de dados, é possível reverter a operação? Em caso afirmativo, como? Senão, por quê?
- 1.4. [Géron 8.4] O PCA pode ser utilizado para reduzir a dimensionalidade de um conjunto de dados altamente não linear?
- 1.5. [Géron 8.5] Suponha que você execute um PCA em um conjunto de dados de mil dimensões ($p = 1000$), definindo a taxa de variância explicada em 95%. Quantas dimensões o conjunto de dados resultante terá?
- 1.6. [Géron 8.7] Como você pode avaliar o desempenho de um algoritmo de redução de dimensionalidade em seu conjunto de dados?
- 1.7. [Géron 8.8] Faz algum sentido juntar dois algoritmos diferentes de redução de dimensionalidade?
- 1.8. Dê exemplos de situações para as quais é mais adequado utilizar o algoritmo t-SNE ou um *autoencoder* ao invés do PCA.
- 1.9. Discorra sobre os prós e contras de PCA, *autoencoder* e t-SNE.

2 Agrupamento (*Clustering*)

- 2.1. [IDM 5.7.2] Encontre todos os grupos “bem separados” (*i.e.*, grupos cujos pontos são mais próximos dos pontos do próprio grupo do que de qualquer outro ponto que pertence a outro grupo).




- 2.2. [IDM 5.7.8] Considere a média de um grupo de objetos de um dataset composto por vetores binários. Quais são os valores mínimo e máximo dos componentes dessa média? Qual é a sua interpretação dos componentes da média do grupo? Que componentes caracterizam de forma mais acurada os objetos no grupo?
- 2.3. [IDM 5.7.13] O diagrama de Voronoi para um conjunto de K pontos no plano é um particionamento de todos os pontos do plano em K regiões, tal que cada ponto (do plano) é assinalado para o ponto mais perto dentre os K pontos especificados (ver figura). Qual é a relação entre diagramas de Voronoi e os grupos do K -médiás? O que diagramas de Voronoi têm a nos dizer sobre a forma dos grupos do K -médiás?



- 2.4. [IDM 5.7.15] Abordagens de agrupamento hierárquico aglomerativo tradicionalmente fusionam dois grupos a cada iteração. Esta abordagem de fato captura a estrutura aninhada do agrupamento de um conjunto de pontos? Se não, explique como você pode posteriormente processar os dados para obter uma visão mais acurada da estrutura do agrupamento.
- 2.5. O que é o “problema da inversão” que pode surgir quando utilizamos o *linkage* centróide no agrupamento hierárquico aglomerativo? Dê um exemplo simples desse problema ocorrendo, ilustrando com um dendrograma.

2.6. Suponhamos que temos um dataset não rotulado onde cada ponto tem dimensão p . Vimos em aula que, se utilizamos a distância Euclidiana para o agrupamento, para evitar que uma determinada dimensão domine o cálculo da distância, temos antes que normalizar as características. Porém, considere que um dataset tenha $p = 2$, e que os gráficos dos pontos não-normalizados e normalizados sejam dados abaixo à esquerda e à direita, respectivamente:



Fonte: Pattern Classification, de Duda, Hart e Stork.

Analise criticamente esta situação.

Referências

- [1] Aurélien Géron. *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems.* "O'Reilly Media, Inc.", 2019.
- [2] Pang-Ning Tan, Michael Steinbach, Anuj Karpatne, and Vipin Kumar. *Introduction to data mining.* Pearson Education India, 2019. Second Edition, Global Edition.